

CENTRO EUROPEO DE MÁSTERES Y POSGRADOS

Máster en Inteligencia Artificial

Producto de IA para la clasificación de pacientes diabéticas

Trabajo de Fin de Máster

Autor: Julio César Tejido González

Director del TFM: Cristian Rodríguez

Curso 2025 / 2026

Anexos

Los anexos reúnen el material que respalda la memoria sin formar parte de su hilo argumental. Todo lo que aquí se referencia está disponible en el repositorio público del proyecto, alojado en https://github.com/cesartejido/TFM_Producto_Diabetes³⁶, cuya organización se describe en el primero de ellos.

Anexo I. Repositorio de código y correspondencia con la memoria

El código completo se publica en abierto y se ofrece en dos formatos equivalentes. El cuaderno original de Google Colab, en formato .ipynb, conserva el código junto a sus salidas y a los comentarios interpretativos de cada paso. Su exportación en .py es el fichero ejecutable que se entrega como anexo de código y que puede abrirse en cualquier entorno de Python sin dependencias del cuaderno. La memoria no reproduce el listado íntegro, y la razón es de criterio: un volcado de varios cientos de líneas resulta ilegible sobre papel y aporta menos que una referencia precisa a la sección concreta donde está cada cosa. Los fragmentos que sí aparecen en el cuerpo del trabajo corresponden a las decisiones metodológicas que consideré más discutibles y que merecían verse tal y como se escribieron.

Anexo II. Diccionario de datos ampliado

La tabla 3 del capítulo 3 describe qué significa clínicamente cada variable. Aquí se completa con su comportamiento estadístico, calculado después de convertir en ausentes los ceros fisiológicamente imposibles y antes de cualquier imputación, que es el momento en el que los datos reflejan exactamente lo que se midió. La columna de asimetría es la que sostiene dos decisiones del capítulo 5: emplear la mediana en lugar de la media como medida de tendencia central y recurrir a contrastes no paramétricos. Los valores por encima de 1 en insulina, función de pedigrí y edad confirman distribuciones con cola derecha marcada. La variable objetivo, que no aparece en la tabla por ser binaria, se reparte en 500 pacientes sin diagnóstico y 268 con él, un 34,9 % de casos positivos.

Variable	n	Media	DT	Mín.	Mediana	Máx.	Asimetría
Pregnancies	768	3,85	3,37	0	3,00	17	0,90
Glucose	763	121,69	30,54	44	117,00	199	0,53
BloodPressure	733	72,41	12,38	24	72,00	122	0,13
SkinThickness	541	29,15	10,48	7	29,00	99	0,69

Variable	n	Media	DT	Mín.	Mediana	Máx.	Asimetría
Insulin	394	155,55	118,78	14	125,00	846	2,17
BMI	757	32,46	6,92	18,20	32,30	67,10	0,59
DiabetesPedigreeFunction	768	0,47	0,33	0,08	0,37	2,42	1,92
Age	768	33,24	11,76	21	29,00	81	1,13

El rango observado de cada variable se contrastó con su plausibilidad clínica antes de decidir qué hacer con los valores extremos. La tabla A4 recoge esa comprobación. Ningún registro se eliminó por atípico, y la decisión tiene dos motivos. El primero es que todos los valores extremos son clínicamente posibles: una insulina de 846 $\mu\text{U/mL}$ encaja con una resistencia severa, y un índice de masa corporal de 67 se ve en obesidad mórbida. El segundo es que con 768 registros y una clase minoritaria de 268 casos, recortar la muestra por criterios estadísticos habría costado potencia sin ganar validez. El único valor que sigo mirando con recelo es el pliegue cutáneo de 99 milímetros, que podría ser un tope de registro más que una medición real, aunque al ser un caso aislado y con un coeficiente final de 0,079 su influencia sobre el modelo es despreciable.

Variable	Rango observado	Criterio de plausibilidad aplicado
Pregnancies	0 a 17	El cero es legítimo, es la única variable donde no indica ausencia
Glucose	44 a 199 mg/dL	Glucemia a las 2 h de sobrecarga oral, el cero es imposible
BloodPressure	24 a 122 mm Hg	Presión diastólica, valores bajos compatibles con hipotensión
SkinThickness	7 a 99 mm	Pliegue del tríceps, el máximo podría ser un tope de registro
Insulin	14 a 846 $\mu\text{U/mL}$	Insulina sérica a las 2 h, el máximo encaja con resistencia severa
BMI	18,2 a 67,1 kg/m^2	Del bajo peso a la obesidad mórbida, todo el rango es posible
DiabetesPedigreeFunction	0,08 a 2,42	Índice adimensional construido por los autores originales
Age	21 a 81 años	Coherente con el criterio de inclusión de la muestra

Anexo III. Cronograma del proyecto

El trabajo se desarrolló entre febrero y agosto de 2026. La tabla A5 recoge el cronograma real, no el previsto, porque el previsto se rompió en abril. La comparación de algoritmos se resolvió antes de lo esperado y en cambio la parte de producto, sobre todo el encaje normativo, consumió mucho más tiempo del que había reservado. La redacción de la memoria no se dejó para el final sino que avanzó en paralelo desde marzo, lo que resultó una de las decisiones más acertadas del proyecto: escribir cada capítulo mientras el

análisis estaba fresco evitó tener que reconstruir después por qué había tomado según qué decisión.

Fase	Feb	Mar	Abr	May	Jun	Jul	Ago
Definición del problema y revisión bibliográfica	X	X					
Recolección y preparación de los datos		X					
Análisis exploratorio		X	X				
Selección y entrenamiento de modelos			X				
Optimización de hiperparámetros			X	X			
Validación, ajuste del umbral e interpretabilidad				X			
Evaluación como producto, regulación y economía				X	X	X	
Redacción de la memoria		X	X	X	X	X	X
Revisión final, anexos y preparación de la defensa							X

Anexo IV. Tablas y resultados complementarios

Este anexo recoge el detalle numérico que el cuerpo de la memoria resume o comenta sin desglosar. La tabla A6 muestra que la estratificación de la partición funcionó como se pretendía, porque la proporción de pacientes diabéticas se mantiene prácticamente idéntica en los tres conjuntos. Un desequilibrio aquí habría invalidado la comparación entre modelos antes de empezar.

Conjunto	Sin diabetes	Con diabetes	% de positivos
Total (n = 768)	500	268	34,9 %
Entrenamiento (n = 614)	400	214	34,9 %
Prueba (n = 154)	100	54	35,1 %

Tabla A6. Balance de clases en el conjunto completo y en las dos particiones.

La tabla A7 completa las matrices de confusión de la figura 10 con las cuatro celdas de cada una, incluidos los verdaderos negativos, que la tabla 11 del cuerpo omitía por centrarse en la clase positiva. Se aprecia con claridad el precio del ajuste: la regresión logística pasa de 72 a 64 verdaderos negativos, es decir, cede ocho pacientes sanas correctamente clasificadas a cambio de detectar ocho enfermas más.

Modelo y umbral	VN	FP	FN	VP
Regresión logística, umbral 0,5	72	28	15	39
Regresión logística, umbral 0,381	64	36	7	47
SVM con núcleo RBF, umbral 0,5	74	26	15	39
SVM con núcleo RBF, umbral 0,258	64	36	9	45

Por último, la tabla A8 documenta la rejilla completa de hiperparámetros que se exploró en el apartado 5.6. Publicarla importa porque el valor seleccionado solo significa algo si se sabe entre qué alternativas se eligió. En la regresión logística el valor ganador, $C = 0,1$, indica una regularización relativamente fuerte, coherente con un conjunto pequeño donde conviene contener la varianza del modelo.

Modelo	Parámetro	Valores explorados	Seleccionado
Regresión logística	C	$0,01 \cdot 0,1 \cdot 1 \cdot 10 \cdot 100$	0,1
Regresión logística	penalty	$l1 \cdot l2$	$l2$
SVM con núcleo RBF	C	$0,1 \cdot 1 \cdot 10 \cdot 100$	1
SVM con núcleo RBF	gamma	$0,001 \cdot 0,01 \cdot 0,1 \cdot 1$	0,01

Las dieciséis figuras que genera el cuaderno están disponibles en resolución original en la carpeta de figuras del repositorio, y las tablas de esta memoria junto con las salidas numéricas del análisis se han depositado en formato reutilizable en la carpeta de anexos³⁶. De ese modo cualquier evaluador puede comprobar los datos sin necesidad de reejecutar el cuaderno completo.